

Text Encoder Deneyleri: Öneri Listesi

aselab Re-ID caption örnekleri (kişi / araç / yüz) · 30 Eylül 2026 · Berke

Bu belge ne? Elimizdeki caption örnekleriyle “text encoder’lar caption’ları nasıl vektöre çeviriyor” sorusunu kurcalamak için bir fikir havuzu. Hepsini yapmak şart değil; ne yapılabileceğini unutmamak ve seçmek için bir liste.

Ana soru. Aynı görselin kısa ve uzun caption’ı benzer vektöre düşüyor mu? Kelime değişimi, özetleme ve kesilme vektörü ne kadar oynatıyor? Farklı encoder’lar bu konuda aynı şeyi mi söylüyor?

Önce bunlarla başla: **D1** kısa ve uzun karşılaştırması, **D2** 77-token kesilmesi, **D3** encoder’lar arası tutarlılık, **D4** kelime değiştirme. Diğerleri bunların üzerine eklenir.

1 Elimizdeki veri

caption_samples_50.zip: domain başına 50 örnek (seed 42, split’e göre dengeli). Her örneğin görseli ve caption’ı birlikte. index.html ile hepsine göz atılabilir, */captions.jsonl ile koddan okunabilir.

Domain	Split (train/query/gallery)	Ort. kelime	CLIP token ort./maks.	>77 token	Not
Kişi	30 / 10 / 10	23	35 / 70	0/50	Kıyafet ağırlıklı, tek cümle
Araç	30 / 10 / 10	15	25 / 44	0/50	Virgüllü liste formatı (v4); yaklaşık 11/50’de marka yok
Yüz	40 train / 10 test	150	218 / 355	50/50	CLIP ortalamada metnin yalnızca yüzde 37’sini görüyor

Token sayıları openai/clip-vit-base-patch16 tokenizer’ı ile ölçüldü (SOT/EOT dahil). Yüzdeki uzunluk farkı kendi başına ilginç bir deney eksenidir; bkz. D2.

2 Denenebilecek text encoder’lar

Dört aile önerisi var. Hepsini değil, her aileden 1–2 model almak yeterli. ✓ işaretli bilgiler bu belge hazırlanırken kaynağından doğrulandı; “kontrol et” olanlar model kartından teyit edilmeli.

Model	HF / kütüphane id	Maks. token	Neden
CLIP ailesi (görselle hizalı, 77 token)			
CLIP ViT-B/16	openai/clip-vit-base-patch16	77 ✓	IRRA baseline'ının encoder'ı; referans nokta
CLIP ViT-L/14	openai/clip-vit-large-patch14	77 ✓	Aynı aile, büyük model etkisi
OpenCLIP ViT-B/16	open_clip: ViT-B-16/laion2b_s34b_b88k	77	Farklı eğitim verisi (LAION); kontrol et
Uzun-context CLIP'ler (görselle hizalı)			
Long-CLIP	BeichenZhang/LongCLIP-B	248 ✓	Uzun caption için; id'yi kontrol et
SigLIP 2	google/siglip2-base-patch16-224	64 ✓	Güncel, çok dilli; padding="max_length" şart
FG-CLIP 2	qihoo360/fg-clip2-base	64 / 196 ✓	İnce taneli hizalama; kısa ve uzun mod ayrı
jina-clip-v2	jinaai/jina-clip-v2	8192 ✓	XLM-RoBERTa metin kolu; Matryoshka 1024→64
Sadece-metin embedder'lar (görsel yok, anlam referansı)			
MiniLM	sentence-transformers/ all-MiniLM-L6-v2	256	Hızlı, ucuz referans; kontrol et
BGE-M3	BAAI/bge-m3	8192	Uzun metin, güçlü retrieval; kontrol et
E5	intfloat/e5-large-v2	512	"query: " öneki gerekir; kontrol et
LLM tabanlı embedder'lar			
Qwen3-Embedding	Qwen/Qwen3-Embedding-0.6B (4B, 8B)	32k ✓	Instruction-aware; MRL ile 32–1024 boyut
LLM2CLIP	Microsoft LLM2CLIP	–	LLM metin kolu CLIP görsel uzayına hizalı; opsiyonel

Önemli ayırım: CLIP ailesi (üst iki blok) görselle hizalı. Bu modellerde text→image retrieval da yapılabilir (D8). Sadece-metin ve LLM embedder'lar görsel görmez; bunlar “iki metin anlamca ne kadar yakın” sorusuna referans olarak kullanılır.

3 Deney menüsü

Her kartta dört alan var: *soru* (ne öğrenmek istiyoruz), *nasıl* (adımlar), *ölçüm* (hangi metrik) ve *beklenti* (tahminimiz; sonuç bunun tersi çıkarsa daha ilginç).

D1 Kısa ve uzun caption aynı vektöre mi düşüyor?	ÖNCELİKLİ
Soru Aynı görselin 1 cümlelik özeti ile tam caption'ı encoder uzayında ne kadar yakın? Nasıl Her caption için bir LLM (Gemini, sadece metin, ucuz) ile sabit prompt kullanarak uzunluk seviyeleri üret: <i>tek cümle</i> (~10 kelime), <i>~20 kelime</i>, <i>~40 kelime</i>, <i>orijinal</i>. Hepsini her encoder'la embed et. Ölçüm (a) $\cos(\text{kısa}, \text{uzun})$, aynı görsel için. (b) Asıl önemli olan: kısa versiyon kendi uzun caption'ına, diğer 49 görselin uzun caption'ından daha mı yakın? Bunu text→text R@1 olarak raporla. Tek başına cosine değeri yanıltıcıdır, (b) ayırt ediciliği ölçer. Beklenti CLIP'te kısa ve uzun versiyonlar yakın çıkar (çünkü zaten baştaki kelimelere bakıyor). Uzun-context modellerde fark açılır.	
D2 77-token kesilmesi ne kaybettiriyor?	ÖNCELİKLİ
Soru Yüz caption'larının tamamı 77 token'ı aşıyor. CLIP bu durumda neyi görüyor, neyi kaybediyor? Nasıl Yüz caption'larını üç şekilde embed et: (i) orijinal (kesilmiş), (ii) sadece ilk 77 token, (iii) cümle sırası karıştırılmış veya ters çevrilmiş. Bunu CLIP ve uzun-context modellerle karşılaştır. Ölçüm CLIP'te $\cos(i, ii) \approx 1$ bekleriz; bu kesilmenin sessizce olduğunu kanıtlar. Sıra değişince vektör ne kadar oynuyor? Cümleleri tek tek çıkarmak da mümkün: hangi cümle vektörü en çok değiştiriyor? Beklenti Long-CLIP makalesine göre CLIP'in <i>efektif</i> uzunluğu 20 token'ın bile altında. Yani kişi ve araç caption'ları bile kısmen “görülüyor” olabilir. Neden önemli Sonuç doğrudan bir karar veriyor: yüz caption'larını kısaltmak mı, uzun-context encoder'a geçmek mi, yoksa en ayırt edici bilgiyi başa almak mı?	

D3 Encoder'lar aynı şeyi söylüyor mu?**ÖNCELİKLİ**

Soru İki caption'ı bir encoder "yakın" buluyorsa diğerleri de buluyor mu?

Nasıl Her encoder için 150×150 cosine benzerlik matrisi çıkar.

Ölçüm Matrislerin üst üçgenleri arasında Spearman korelasyonu; her caption'ın 10 en yakın komşusunun encoder'lar arası örtüşmesi (kNN overlap@10). İstenirse CKA.

Not Mutlak cosine değerleri encoder'lar arasında karşılaştırılmaz. CLIP'te 0.8 ile BGE'de 0.8 aynı anlama gelmez. Sıralama ve korelasyon karşılaştır.

D4 Kelime değiştirme (exchange / swap) hassasiyeti**ÖNCELİKLİ**

Soru Encoder, anlamı değiştiren küçük bir kelime değişikliğini fark ediyor mu?

Nasıl Her caption için kontrollü varyantlar üret:

- *renk değiştir*: "red jacket" → "blue jacket"
- *nitelik takası*: "red jacket, blue pants" → "blue jacket, red pants". Kelimeler aynı, eşleşme farklı.
- *marka/model değiştir* (araç): "Toyota Camry" → "Honda Accord"
- *yaş/cinsiyet/aksesuar değiştir* (yüz, kişi)
- *paraphrase*: anlam aynı, kelimeler farklı. Bu kontrol grubu.

Ölçüm $\Delta \cos = \cos(\text{orijinal, paraphrase}) - \cos(\text{orijinal, swap})$. Pozitif ve büyükse encoder değişikliği fark ediyor demektir.

Beklenti CLIP benzeri modeller "kelime torbası" gibi davranıyor (ARO, SugarCreme). Nitelik takasında vektör neredeyse hiç değişmeyebilir. Bu sonuç Re-ID için kritik, çünkü "kırmızı ceket, mavi pantolon" ile tersini ayırt edemeyen bir model kişi aramada hata yapar.

D5 Paraphrase dayanıklılığı

Soru Aynı anlamı farklı kelimelerle söylediğimizde vektör sabit kalıyor mu?

Nasıl Her caption için 3 paraphrase üret (D4'ün kontrol grubu yeniden kullanılabilir).

Ölçüm Paraphrase'ler arası ortalama cosine ve varyans. D4 ile birlikte bir "hassasiyet marjı" verir: iyi bir encoder paraphrase'de sabit kalır, swap'ta değişir.

D6 Olumsuzluk (negation)

Soru "wearing glasses" ile "not wearing glasses" ayrı vektörlere düşüyor mu?

Nasıl Kişi ve yüz caption'larında bir niteliği olumsuzla.

Beklenti NegBench (CVPR 2025) CLIP tabanlı modellerde olumsuzluğun neredeyse şans seviyesinde anlaşıldığını gösteriyor. Bu deney caption kuralımızı ("negation yazma") kendi verimizde doğrulamış olur. LLM embedder'ların burada farklı davranıp davranmadığı ilginç.

D7 Domain ayrışması ve "şablon çökmesi"

Soru Caption'lar domain'e göre kümeleniyor mu? Domain içinde birbirinden yeterince ayrılıyorlar mı?

Nasıl 150 embedding'i UMAP/t-SNE ile 2B'ye indir, domain'e göre renklendir.

Ölçüm Silhouette skoru; domain içi ortalama pairwise cosine. Bu değer çok yüksekse caption'lar birbirine benziyor demektir (şablon tekrarı), bu da ayırt ediciliğin düşük olduğunu gösterir.

Beklenti Yüz caption'ları çok şablonlu ("Male-presenting ... oval facial shape, balanced thirds ..."). Domain içi benzerlik en yüksek orada çıkabilir.

D8 Mini text→image retrieval (sadece CLIP ailesi)

Soru Metin tarafındaki farklar gerçek eşleştirme başarısına yansıyor mu?

Nasıl Her domain'de 50 görsel galeri, 50 caption sorgu. Orijinal, kısa ve kesilmiş versiyonlarla tekrarla.

Ölçüm R@1, R@5, mAP. Galeri küçük olduğu için sayılar iyimser çıkar. Mutlak değerlere değil, varyantlar arası farka bak.

Neden önemli D1–D4'ün "vektör değişti" bulgularını "eşleştirme bozuldu mu" sorusuna bağlar. Re-ID metriklerine en yakın deney bu.

D9 Hangi kelimeler vektörü taşıyor?

Soru Caption'ın hangi kısmı embedding'e en çok katkı veriyor?

Nasıl Her seferinde bir nitelik ya da cümle çıkar (ablation) ve tam caption'a olan cosine düşüşünü ölç.

Beklenti CLIP'te baştaki kelimelerin baskın olması (pozisyon yanlılığı). Araçta tip ve marka, kişide cinsiyet ve üst giysi öne çıkabilir.

D10 Pooling ve instruction etkisi (sadece-metin / LLM)

Soru Aynı model farklı pooling veya instruction ile farklı sonuç veriyor mu?

Nasıl Mean pooling, CLS token ve son token karşılaştır; Qwen3-Embedding'i instruction'lı ve instruction'sız dene (ör. "Given a person description, retrieve images of the same person").

Not Model kartının önerdiği pooling'i varsayılan al; bu deney opsiyonel bir ek.

4 Pratik notlar ve tuzaklar

- **Varyantları tek dosyada tut.** Örnek şema: `variants.jsonl` içinde `{id, domain, split, variant, text};` variant alanı `orig, sum10, sum20, para1, swap_color, neg, trunc77` gibi değerler alır. Böylece her encoder aynı girdiyi görür.
- **Embedding'leri cache'le:** `emb/{encoder}.npy` ve satır sırası `variants.jsonl` ile aynı. Analiz her seferinde yeniden encode etmeden koşar.
- **L2-normalize et**, sonra cosine hesapla. SigLIP 2'de `padding="max_length", max_length=64` kullan, yoksa sonuçlar bozuk çıkar.
- **Kesilmeyi logla.** CLIP tokenizer'ı `truncation=True` ile sessizce keser. Her encoder için "kaç token kesildi" sütunu tut.
- **Üretim prompt'larını sabitle.** Özet, paraphrase ve swap prompt'larını dosyaya yaz, temperature'ı düşük tut. Aksi halde farkın kaynağı encoder mı, LLM mi, ayırt edilemez.
- **İstatistik.** Domain başına 50 örnek var. Ortalama $\pm$ std ve bootstrap güven aralığı raporla. Küçük farkları abartma; gerekirse örnek sayısını artırırız (script hazır).
- **Donanım.** CLIP ailesi ve MiniLM CPU'da bile koşar. Qwen3-Embedding 4B/8B ve LLM2CLIP için GPU gerekir.

5 Önerilen sıra

1. Varyant üretimi (özet seviyeleri, paraphrase, swap, negation) $\rightarrow$ `variants.jsonl`
2. Her aileden bir model ile başla: CLIP B/16, Long-CLIP, MiniLM, Qwen3-Embedding-0.6B
3. D1 + D2 + D3 + D4, sonra D8 (retrieval) ile bağla
4. Sonuçlar ilginçse diğer encoder'lar ve D5–D7, D9–D10
5. Çıktı: encoder $\times$ deney tablosu + 2–3 grafik (UMAP, $\Delta_{\cos}$ bar, kesilme eğrisi)

Özetle

Bir cümleyi bir modele verdiğimizde model onu bir sayı dizisine, yani "parmak izine" çeviriyor. Bu listedeki deneyler o parmak izinin neye duyarlı olduğunu anlamaya çalışıyor.

- "Kırmızı ceketli kadın" ile uzun, detaylı hali aynı parmak izini mi veriyor? (D1)
- Yüz caption'larının üçte ikisi modelin okuyabileceği sınırın dışında kalıyor mu? (D2)
- "Kırmızı ceket, mavi pantolon" ile "mavi ceket, kırmızı pantolon" aynı izi mi bırakıyor? Bırakıyorsa model kişileri karıştırır. (D4)

Bu sorulara verilen cevaplar, caption'ları kısaltıp kısaltmayacağımıza ve hangi encoder'la devam edeceğimize karar vermemizi sağlayacak.

Kaynaklar

- Zhang ve ark., *Long-CLIP: Unlocking the Long-Text Capability of CLIP*, ECCV 2024. <https://arxiv.org/abs/2403.15378>
- Tschannen ve ark., *SigLIP 2*, 2025. <https://arxiv.org/abs/2502.14786>; HF notu: <https://huggingface.co/blog/siglip2>
- Xie ve ark., *FG-CLIP: Fine-Grained Visual and Textual Alignment*, ICML 2025. <https://arxiv.org/abs/2505.05071>; model/kod: <https://github.com/360CVGroup/FG-CLIP>
- Koukounas ve ark., *jina-clip-v2*, 2024. <https://arxiv.org/abs/2412.08802>
- Qwen3-Embedding model kartı. <https://huggingface.co/Qwen/Qwen3-Embedding-0.6B>

- Huang ve ark., *LLM2CLIP*, AAAI. <https://arxiv.org/abs/2411.04997>
- Yuksekgonul ve ark., *When and Why Vision-Language Models Behave like Bags-of-Words (ARO)*, ICLR 2023. <https://arxiv.org/abs/2210.01936>
- Hsieh ve ark., *SugarCrepe*, NeurIPS 2023 Datasets & Benchmarks. <https://arxiv.org/abs/2306.14610>
- Alhamoud ve ark., *Vision-Language Models Do Not Understand Negation (NegBench)*, CVPR 2025. <https://arxiv.org/abs/2501.09425>
- Jiang ve Ye, *Cross-Modal Implicit Relation Reasoning and Aligning for Text-to-Image Person Retrieval (IRRA)*, CVPR 2023. <https://arxiv.org/abs/2303.12501>